

Dokumentacja Projektu

System Scoringu Kredytowego z Wykorzystaniem

Algorytmu XGBoost

Tomasz Dylik

6 czerwca 2026

Streszczenie

Niniejszy dokument stanowi kompleksowe podsumowanie projektu analitycznego, którego celem było stworzenie systemu predykcyjnego oceniającego ryzyko kredytowe klientów (Credit Scoring). Projekt obejmował pełen cykl Data Science: od czyszczenia i inżynierii cech, przez eksploracyjną analizę z wykorzystaniem reguł asocjacyjnych (Apriori), balansowanie klas algorytmem SMOTE, aż po optymalizację uczenia maszynowego (XGBoost). Ostatecznym rezultatem jest nie tylko model o wysokiej skuteczności statystycznej, ale przede wszystkim narzędzie biznesowe maksymalizujące zysk operacyjny instytucji finansowej.

Spis treści

1	Wstęp i Charakterystyka Danych	2
2	Przetwarzanie Danych (Preprocessing)	2
2.1	Balansowanie Klas za pomocą SMOTE	2
3	Logika Biznesowa i Reguły Asocjacyjne (Apriori)	2
4	Modelowanie i Wybór Algorytmu	3
5	Wyjaśnialność Modelu (Feature Importance)	3
6	Wdrożenie Biznesowe: System Scoringowy	4
7	Symulacja Finansowa i Maksymalizacja Zysku	4
7.1	Statystyka vs Biznes (Trade-off)	5
8	Podsumowanie	6

1 Wstęp i Charakterystyka Danych

Podstawą projektu był zbiór danych zawierający 32 581 rekordów reprezentujących historyczne wnioski kredytowe. Zbiór składał się z 12 zmiennych, w tym danych demograficznych (wiek, dochód), informacji o zatrudnieniu, parametrów kredytu (kwota, oprocentowanie, ocena ryzyka banku) oraz zmiennej docelowej określającej, czy klient spłacił zobowiązanie (*loan_status*).

Głównym wyzwaniem zidentyfikowanym na wczesnym etapie był znaczny brak balansu klas. Klienci rzetelni stanowili około 80% zbioru, podczas gdy bankruci (Default) zaledwie 20%.

2 Przetwarzanie Danych (Preprocessing)

Aby zapewnić wysoką jakość wejścia dla algorytmów uczenia maszynowego, przeprowadzono następujące kroki:

- **Usunięcie anomalii:** Wyeliminowano wartości odstające (outliery), takie jak nie-realistyczny wiek wnioskodawcy (np. powyżej 100 lat) czy niemożliwy staż pracy. Usunięto łącznie 7 uszkodzonych rekordów.
- **Imputacja braków danych:** Braki w zmiennych ciągłych (takich jak długość zatrudnienia czy oprocentowanie) zostały uzupełnione wartością mediany wyliczoną ze zbioru treningowego, co pozwoliło uniknąć zaburzenia naturalnych rozkładów.
- **Kodowanie zmiennych (One-Hot Encoding):** Zmienne kategoryczne zamieniono na format numeryczny. Proces ten rozszerzył przestrzeń cech z 11 zmiennych bazowych do 26 niezależnych zmiennych binarnych i ciągłych (m.in. rozbiecie statusu mieszkaniowego na osobne flagi RENT, OWN, MORTGAGE).

2.1 Balansowanie Klas za pomocą SMOTE

Z powodu wspomnianej dysproporcji (20 373 klientów rzetelnych vs 5 686 dłużników w zbiorze treningowym), tradycyjne algorytmy miały tendencję do faworyzowania klasy większościowej. Zastosowano technikę **SMOTE** (Synthetic Minority Over-sampling Technique) wyłącznie na zbiorze treningowym. Wygenerowano syntetyczne profile dłużników, doprowadzając do idealnego balansu 50/50.

3 Logika Biznesowa i Reguły Asocjacyjne (Apriori)


Przed zastosowaniem zaawansowanych modeli predykcyjnych, zbiór poddano analizie za pomocą algorytmu *Apriori*. Celem było zweryfikowanie, czy w danych istnieją twarde, logiczne wzorce zachowań klientów. Najsilniejszy wyodrębniony wzorzec to:

$$\text{Wynajem Mieszkania} + \text{Niskie Dochody} + \text{Wysoka Rata} \implies \text{Default}$$

Reguła ta cechowała się wskaźnikiem pewności (Confidence) na poziomie 63.6% oraz wartością Lift równą 2.9 (ryzyko bankructwa niemal trzykrotnie wyższe w stosunku do ryzyka bazowego).

4 Modelowanie i Wybór Algorytmu

W ramach laboratorium modeli, dane poddano klasyfikacji przy użyciu popularnych algorytmów uczenia maszynowego. Głównym kryterium wyboru była metryka **F1-Score** oraz **Recall**, pozwalające na znalezienie kompromisu między wyłapywaniem oszustów a nieodrzucającym rzetelnych klientów.




Rysunek 1: Porównanie skuteczności wyłapywania oszustów (metryka Recall) dla badanych modeli. Zwycięski XGBoost wykazał się najlepszym balansem między czułością a minimalizacją fałszywych alarmów.

Wybrano algorytm **XGBoost (eXtreme Gradient Boosting)**. Jego przewaga wynika z sekwencyjnej metody uczenia (kolejne drzewa korygują błędy poprzednich), co pozwoliło na drastyczne zminimalizowanie wskaźnika fałszywych alarmów z 543 (w przypadku Decision Tree) do zaledwie 56.

5 Wyjaśnialność Modelu (Feature Importance)

Aby zniwelować problem tzw. "czarnej skrzynki", przeanalizowano ważność cech w architekturze XGBoost z wykorzystaniem metryki zysku informacyjnego (Gain).




Rysunek 2: Top 10 najważniejszych cech z punktu widzenia algorytmu XGBoost (metryka Gain). Zmienna dotycząca wynajmu mieszkania (RENT) okazała się najważniejszym predyktorem w całym zbiorze.

Warto zauważyć, że kategoria ryzyka *Grade C* uzyskała bardzo wysoką wagę. Wynika to z faktu, że skrajnie złe oceny (np. *Grade G*) dotyczą zbyt małego odsetka klientów, by stanowić o globalnej sile modelu, podczas gdy *Grade C* stanowi masową "szarą strefę", w której poprawne rozdzielanie klientów generuje największy zysk punktowy dla algorytmu.

6 Wdrożenie Biznesowe: System Scoringowy

Output modelu XGBoost został przekształcony w elastyczny silnik scoringowy, przypisujący każdemu klientowi precyzyjne prawdopodobieństwo braku spłaty (Risk Score 0–100%).




Rysunek 3: Rozkład Risk Score. Model skutecznie odseparował rzetelnych kredytobiorców (skupieni po lewej stronie) od profili wysokiego ryzyka (wyraźny pik po prawej stronie).

Podjęcie to nakłada na model warstwę biznesową, pozwalając na elastyczne zarządzanie apetytem na ryzyko instytucji, bez konieczności ingerencji w kod źródłowy sztucznej inteligencji.

7 Symulacja Finansowa i Maksymalizacja Zysku

Ostatnim etapem projektu była bezpośrednia optymalizacja decyzji pod kątem finansowym (ROI). Skrypt analizujący portfel wyliczył dynamicznie średnią kwotę wnioskowanego kredytu (ok. 9 589 USD) i założył 10% marży oraz 100% straty kapitału w przypadku oszustwa.




Rysunek 4: Krzywa optymalizacji zysku operacyjnego. Najwyższy matematyczny zysk portfela zostaje osiągnięty przy odrzucaniu wniosków powyżej progu 29%.

Przeprowadzona symulacja udowadnia, że tradycyjny próg odcięcia na poziomie 50% (stosowany powszechnie w statystyce) nie jest optymalny dla zysków firmy. Aby zmaksymalizować wynik finansowy, system rekomenduje agresywniejsze odcinanie ryzyka (ok. 29%).

7.1 Statystyka vs Biznes (Trade-off)

Obniżenie progu akceptacji do poziomu zoptymalizowanego biznesowo wiąże się ze zjawiskiem *Trade-off*.



Standardowy próg (50%)

Próg biznesowy (~29%)

Rysunek 5: Porównanie macierzy pomyłek. Model biznesowy odrzuca więcej uczciwych klientów, ale pozwala uchronić kapitał przed większą liczbą bankrutów.

Jak ukazuje powyższe zestawienie, próg zoptymalizowany biznesowo powoduje częstsze odrzucanie uczciwych klientów (wzrost False Positives). Jednakże wynikająca z tego drastyczna redukcja przepuszczonych bankrutów (False Negatives) udowadnia twardą matematykę finansową: uniknięcie straty ogromnego kapitału jest zawsze bardziej opłacalne niż pogoń za prowizją z każdego klienta.

8 Podsumowanie

Stworzony system klasy Credit Scoring oparty na architekturze XGBoost udowadnia, że zaawansowane metody inżynierii danych mogą stanowić fundamentalne narzędzie w procesie decyzyjnym. Świadome zrezygnowanie z klasycznego podejścia maksymalizacji podstawowych metryk statystycznych na rzecz optymalizacji parametrów finansowych, definiuje ten projekt jako dojrzałe, kompleksowe rozwiązanie analityczne.